

World Action Model • 2026 分类全索引

WAM 专题 • 综合 4 个 awesome 仓库 + 2 篇综述

Liuyue

2026-05-29

Contents

0. 综述与 Awesome 仓库	2
0.1 核心综述	2
0.2 Awesome 仓库	2
0.3 与 VLA 的关系（一句话）	2
1. Cascaded WAM（先生成未来，再解动作）	2
1.1 Explicit Pixel-Space • Learned Action Extraction	2
1.2 Explicit Pixel-Space • Geometric Extraction	3
1.3 Implicit Planning • Latent Representation	3
2. Joint WAM（世界 + 动作一锅炖）	3
2.1 Autoregressive • Explicit Decoupled	3
2.2 Autoregressive • Unified Discrete	4
2.3 Autoregressive • Predictive Latent (JEPA-style)	4
2.4 Diffusion-Based • Unified Stream • Explicit Future	4
2.5 Diffusion-Based • Unified Stream • Implicit Future	4
2.6 Diffusion-Based • Multi-Stream • Cross-Attention	4
2.7 Diffusion-Based • Multi-Stream • Hidden-State Coupling	5
2.8 Diffusion-Based • Multi-Stream • Shared Representation	5
3. WAM 按“来源”分类（DravenALG 视角）	5
3.1 WAM from VideoGen（视频生成模型改造）	5
3.2 WAM from VLM（视觉语言模型改造）	5
3.3 WAM from Scratch（从零训练）	6
4. World Model as Simulator（不当 policy，当训练/评估环境）	6
4.1 WM 内部跑 RL • Learned Simulator	6
4.2 Co-Evolution（策略与 WM 互相打磨）	7
4.3 WM for Imitation Learning（生成训练数据）	7
4.4 WM for Evaluation / MPC	7
5. Robotic Video World Models（Foundation-scale）	8
5.1 Video as Imagination	8
5.2 Action-Controllable Video WM	8
5.3 Structure-Aware Generation	8
5.4 Foundation-Scale Video World Models	8
6. Latent / Symbolic World Models	9
6.1 Neural Latent	9
6.2 Symbolic / Planner-Facing WM	9
7. WAM 训练数据生态	9
7.1 Robot-Centric Teleoperation Datasets	9

7.2 Portable Human Demonstration	10
7.3 Simulation	10
7.4 Internet-Scale Egocentric Video	10
8. 经典 World Model (奠基工作, 不限机器人)	10
8.1 Dreamer 系列	10
8.2 Transformer-based World Models	11
8.3 JEPA / Latent	11
8.4 历史奠基 (pre-2020)	11
9. Navigation / Driving WM (应用线)	11
9.1 Navigation WM	11
9.2 Autonomous Driving WM	12
10. 选读建议 (按身份)	12

0. 综述与 Awesome 仓库

0.1 核心综述

- [World Action Models: The Next Frontier in Embodied AI \(S2\)](#) — **第一篇 WAM 专门综述**。正式定义 “World Action Model” 概念, 给出 Cascaded vs Joint 二分法。
- [World Model for Robot Learning: A Comprehensive Survey \(S1\)](#) — 把 World Model 在机器人里的三种用法 (policy / simulator / video generation) 完整梳理。
- [A Comprehensive Survey on World Models for Embodied AI](#)
- [A Review of Learning-based Dynamics Models for Robotic Manipulation](#) — Science Robotics 2025

0.2 Awesome 仓库

- [OpenMOSS/Awesome-WAM](#) • S2 配套, 最权威
- [NTUMARS/Awesome-World-Model-for-Robotics-Policy](#) • S1 配套
- [DravenALG/awesome-vla-wam](#) • 按来源切 (VideoGen / VLM / Scratch)
- [leofan90/Awesome-World-Models](#)
- [knightnemo/Awesome-World-Models](#)
- [operator22th/awesome-world-models-for-robots](#)
- [LMD0311/Awesome-World-Model](#)

0.3 与 VLA 的关系 (一句话)

WAM = VLA + 显式建模 “动作如何改变世界”。所有 WAM 砍掉未来预测头就是 VLA; 所有 VLA 加上未来预测头就是 WAM。下面的分类按 S2 综述的 Cascaded/Joint 主轴展开。

1. Cascaded WAM (先生成未来, 再解动作)

核心思想: 解耦——世界模型负责 “画出未来会发生什么”, 独立的动作 module 再从画出来的未来里反推动作。 早期范式 (2023-2024 主流), 优点是模块化、可解释, 缺点是两段误差会累积。

1.1 Explicit Pixel-Space • Learned Action Extraction

世界模型直接生成像素级未来视频, 下游用一个 learned policy/decoder 从生成视频里推动作。π0.7 是 2026 H1 首批落地实体产品的 cascaded WAM 代表作。

- [UniPi](#) — 开山之作, Universal Policies via Text-Guided Video
- [VLP \(Video Language Planning\)](#)

- [ThisAndThat](#)
- [Gen2Act](#)
- [TesserAct](#)
- [Vidar](#)
- [RoboEnvision](#)
- [MVISTA-4D](#)
- [Say-Dream-Act](#)
- [Veo-Act](#)
- [VAG](#)
- [π0.7](#)
- [TC-IDM](#)

1.2 Explicit Pixel-Space • Geometric Extraction

世界模型生成视频，但下游不学动作映射，而是从视频里抽几何结构（2D flow / 3D point flow / 3D hand trajectory），再用经典控制或 IK 接到机器人——对硬件适配最友好，跨 embodiment 迁移强。

- [AVDC](#) — 视频自监督学动作
- [Im2Flow2Act](#)
- [Dreamitate](#)
- [3DFlowAction](#)
- [NovaFlow](#)
- [VidBot](#)
- [4DGen](#)
- [RIGVid](#)
- [LV-P](#)
- [Dream2Flow](#)
- [Hind4sight-Net](#) — 早期奠基

1.3 Implicit Planning • Latent Representation

世界模型不生成像素也不抽几何，只产出 latent 中间表示作为“计划”，下游 policy 在 latent 上规划动作。比像素生成省算力数量级。

- [ARDuP](#)
- [VPP \(Video Prediction Policy\)](#)
- [LaPA](#)
- [VILP](#)
- [VideoPolicy](#)
- [villa-X](#)
- [mimic-video](#)
- [S-VAM](#)
- [OmniVTA](#)
- [MWM](#)

2. Joint WAM（世界 + 动作一锅炖）

核心思想：一个模型同时输出未来状态和动作，避免误差累积，紧耦合。2025 Q4 开始成为主流，2026 H1 已经基本统治 SOTA。

2.1 Autoregressive • Explicit Decoupled

未来状态和动作都做成 token，丢同一个 transformer 自回归生成，但未来 token 和动作 token 在序列里分开。GR-1/2/MG 是 ByteDance 这条线的代表。

- [GR-1](#)
- [GR-2](#)
- [GR-MG](#)

2.2 Autoregressive • Unified Discrete

把未来帧和动作完全统一到一个离散 token 空间里——彻底用 LLM 训练栈。WorldVLA / F1 / CoT-VLA 是这一支。

- [CoT-VLA](#)
- [WorldVLA](#)
- [F1](#)
- [RynnVLA-002](#)
- [MM-ACT](#)
- [FlowVLA](#)

2.3 Autoregressive • Predictive Latent (JEPA-style)

不预测像素 token，预测一个紧凑的 latent embedding——继承 LeCun JEPA 路线。

- [VLA-JEPA](#)
- [JEPA-VLA](#)
- [V-JEPA 2](#)
- [V-JEPA 2.1](#)
- [WoG \(World Guidance\)](#)
- [DIAL](#)

2.4 Diffusion-Based • Unified Stream • Explicit Future

未来帧 token 和动作 chunk 在同一 token stream 里 joint denoise——大厂 foundation WAM 主流选择。Cosmos Policy / DreamZero / GigaWorld-Policy / X-WAM 是 2026 重磅。

- [PAD](#)
- [UWM](#)
- [VideoVLA](#)
- [Cosmos Policy](#)
- [DreamZero](#)
- [GigaWorld-Policy](#)
- [X-WAM](#)

2.5 Diffusion-Based • Unified Stream • Implicit Future

未来不显式预测，但 diffusion process 内部带有 latent future 监督。

- [FLARE](#)
- [FRAPPE](#)

2.6 Diffusion-Based • Multi-Stream • Cross-Attention

世界和动作各走一条 diffusion 分支，通过 cross-attention 在中间层互通。

- [DUST](#)
- [UD-VLA](#)
- [Motus](#)
- [CoVAR](#)

2.7 Diffusion-Based • Multi-Stream • Hidden-State Coupling

两条分支通过 hidden state 在中间层硬耦合。2026 H1 学术界最活跃的子方向——LingBot-VA / Fast-WAM / DiT4DiT / MotuBrain 都是这条线。

- [LingBot-VA](#)
- [LDA-1B](#)
- [AdaWorldPolicy](#)
- [AIM](#)
- [DexWorldModel](#)
- [MotuBrain](#)
- [Act2Goal](#)
- [DiT4DiT](#)
- [Fast-WAM](#)
- [WAV](#)

2.8 Diffusion-Based • Multi-Stream • Shared Representation

两条分支共享底层 representation backbone，再分头解码。

- [UVA](#)
 - [PhysGen](#)
-

3. WAM 按“来源”分类（DravenALG 视角）

S2 是按“耦合方式”切，DravenALG 提出按“WAM 怎么训出来的”切，这两个 taxonomy 互补。

3.1 WAM from VideoGen（视频生成模型改造）

从已有视频生成 foundation model（Cosmos、Sora-类）出发，加上动作分支微调。优点是利用了 internet-scale 视频预训练。

- [UniPi](#)
- [VLP](#)
- [GR-1](#)
- [GR-2](#)
- [VPP](#)
- [Inverse Probabilistic Adaptation](#)
- [DreamGen](#)
- [UniVLA \(task-centric\)](#)
- [VideoPolicy](#)
- [mimic-video](#)
- [LingBot-VA](#)
- [World-VLA-Loop](#)
- [Cosmos Policy](#)
- [DreamZero](#)
- [Do WAMs Generalize Better?](#)
- [Fast-WAM](#)
- [GigaWorld-Policy](#)

3.2 WAM from VLM（视觉语言模型改造）

从 VLM/MLLM 出发加未来预测头。继承语言推理能力，更适合 long-horizon 任务。

- [UP-VLA](#)
- [CoT-VLA](#)

- FLARE
- WorldVLA
- UniVLA
- DreamVLA
- FlowVLA
- F1
- RynnVLA-002
- MM-ACT
- VLA-JEPA
- LDA-1B
- VLAW
- WoG
- $\pi 0.7$

3.3 WAM from Scratch (从零训练)

世界模型和动作模型一起从零联合训。和经典 Dreamer / GameNGen 这条 RL 世界模型路线接得最直接。

- DayDreamer
- DreamerV3
- Dynalang
- UniSim
- AVDC
- LAPO
- DIAMOND
- GameNGen
- GameGen-X
- NWM
- Moto
- Seer
- UVAM
- UWM
- CoMo
- LPS
- LeWorldModel
- WAV
- Being-H0.7

4. World Model as Simulator (不当 policy, 当训练/评估环境)

世界模型本身当 sim 用——给策略训 RL、给策略评估打分。**Sim-to-real 的另一种解法**：不再追求把 sim 做得像 real，而是让 sim 从 real data 里学出来。

4.1 WM 内部跑 RL • Learned Simulator

策略在学得的世界模型里跑 PPO/GRPO/SAC——把“无数次真机试错”换成“无数次脑内试错”。UniSim 开山，VLA-RFT / WMPO / World4RL 把它做成单卡级别的 VLA 后训练。

- DayDreamer
- UniSim
- DreamerV3
- PlaNet
- Dream to Control
- DreamerV2
- Transformer-based WM (IRIS)

- [MoDem-V2](#)
- [VIPER](#)
- [Diffusion Reward](#)
- [RWM-U](#)
- [DiWA](#)
- [World4RL](#)
- [Dreamer 4](#)
- [World-Env](#)
- [VLA-RFT](#)
- [PhysWorl](#)
- [WMPO](#)
- [SRPO](#)
- [ProphRL](#)
- [GenReward](#)
- [RoboScape-R](#)
- [World-Gymnast](#)
- [RWML](#)
- [RISE](#)
- [GigaBrain-0.5M](#)
- [RehearseVLA](#)

4.2 Co-Evolution (策略与 WM 互相打磨)

不再只用固定 WM 训策略——失败 rollout 反过来纠正 WM，更新过的 WM 再回训策略。2026 H1 兴起。

- [World-VLA-Loop](#)
- [VLAW](#)
- [WoVR](#)
- [PlayWorld](#)
- [VLA-MBPO](#)
- [ViVa](#)

4.3 WM for Imitation Learning (生成训练数据)

世界模型当数据工厂——给目标条件，直接 rollout 出训练 trajectory。

- [DREMA \(Dream Manipulation\)](#)
- [RoboScape](#)
- [Ctrl-World](#)
- [DreamGen](#)
- [RoboDreamer](#)
- [ManipDreamer](#)
- [PhysWorld](#)

4.4 WM for Evaluation / MPC

把 WM 当离线评估器：候选动作在 WM 里展开 rollout 打分。

- [TD-MPC2](#)
- [WorldEval](#)
- [WorldGym](#)
- [GPC](#)
- [IRASim](#)
- [Veo Evaluator \(Gemini Robotics\)](#)
- [Scalable Policy Evaluation](#)
- [DreamPlan](#)
- [LeWorldModel](#)
- [Interactive World Simulator](#)

- [dWorldEval](#)
 - [WorldArena](#)
 - [FFDC-WAM](#)
-

5. Robotic Video World Models (Foundation-scale)

机器人专用视频生成模型——能力级别从“凭想象画一段”逐步演化到“foundation-scale 通用世界引擎”。

5.1 Video as Imagination

不要求动作可控、不要求物理一致，先把“长得对”做出来。

- [UniPi](#)
- [VLP](#)
- [Dreamitate](#)
- [RoboDreamer](#)
- [ManipDreamer](#)
- [DreMa](#)
- [DreamGen](#)
- [EnerVerse](#)

5.2 Action-Controllable Video WM

接受动作序列作为条件输入，输出对应未来视频——可交互 simulator 的前提。

- [IRASim](#)
- [RoboEnvision](#)
- [RoboMaster](#)
- [Ctrl-World](#)
- [EnerVerse-AC](#)
- [Interactive World Simulator](#)
- [EVA](#)
- [Inverse Probabilistic Adaptation](#)

5.3 Structure-Aware Generation

加入物理 / 几何 / 交互先验，保证生成视频物理自洽。

- [Mask2IV](#)
- [TesserAct](#)
- [RoboVIP](#)
- [PhysWorld](#)
- [3DFlowAction](#)

5.4 Foundation-Scale Video World Models

大规模通用视频世界模型——参数 + 数据两端拉到 foundation 量级。

- [Genie](#)
- [Genie Envisioner](#)
- [Cosmos](#)
- [Cosmos Predict 2.5](#)
- [Vid2World](#)
- [DreamDojo](#)
- [WoW](#)
- [UnifoLM-WMA-0 \(Unitree\)](#)

- [GigaWorld-0](#)
 - [ABot-PhysWorld](#)
 - [Yume](#)
 - [Matrix-Game](#)
 - [WorldMem](#)
 - [PlayerOne](#)
 - [The Matrix](#)
 - [GameFactory](#)
 - [Puffin](#)
 - [CoLA-World](#)
 - [NitroGen](#)
 - [Learning Latent Action WM](#)
 - [PointWorld](#)
-

6. Latent / Symbolic World Models

不预测像素的紧耦合 WM——latent neural representation 或 symbolic representation。

6.1 Neural Latent

未来在 embedding 空间预测，不渲染像素——继承 LeCun JEPA 路线，训练效率最高，可解释性最弱。V-JEPA 2/2.1 是 Meta 主力，VLA-JEPA / WoG / DIAL 把它接到机器人控制上。

- [FLARE](#)
- [V-JEPA 2](#)
- [V-JEPA 2.1](#)
- [VLA-JEPA](#)
- [JEPA-VLA](#)
- [VISTA](#)
- [WoG](#)
- [DIAL](#)
- [AIM](#)
- [DexWorldModel](#)
- [AdaWorld](#)

6.2 Symbolic / Planner-Facing WM

谓词、对象关系、affordance、因果过程——给经典 planner 用的世界模型抽象。和 neural latent 互补：可解释、可组合，但难以处理感知细节。

- [Liang et al. 2025c](#)
 - [Athalye et al. 2026](#)
 - [3D-VLA](#)
-

7. WAM 训练数据生态

S2 把数据按“来源”分四类——和 VLA 不同的是 WAM 更能消化无动作标注的数据（egocentric video、play data）。

7.1 Robot-Centric Teleoperation Datasets

对齐的 state-action 对，sim-to-real gap 最小，但采集贵且覆盖窄。Open X-Embodiment 是跨 22 机器人本体的总聚合，DROID 主打 in-the-wild 多样性。

- [QT-Opt](#)
- [MIME](#)
- [RoboNet](#)
- [RoboTurk](#)
- [Bridge](#)
- [MT-Opt](#)
- [BC-Z](#)
- [Language-Table](#)
- [RT-1 Dataset](#)
- [BridgeData V2](#)
- [Cable-Routing](#)
- [RH20T](#)
- [Open X-Embodiment](#)
- [DROID](#)

7.2 Portable Human Demonstration

便携式硬件采人类演示，再重定向到机器人——绕开真机采集瓶颈。UMI 用 GoPro 手持式 gripper 在野外采数据，比真机快 3 倍；DexCap 用 EMF 手套捕捉灵巧操作。

- [UMI](#)
- [DexCap](#)
- [ALOHA](#)
- [GELLO](#)

7.3 Simulation

有特权物理监督、可规模化变种。SynGrasp-1B 提供 billion 级合成抓取轨迹；MimicGen/GenSim/RoboGen 是自动生成 sim 任务和轨迹的引擎。

- [RoboCasa](#)
- [RoboGen](#)
- [MimicGen](#)
- [GenSim](#)
- [RoboTwin 2.0](#)
- [SynGrasp-1B](#)

7.4 Internet-Scale Egocentric Video

人类第一视角视频——WAM 训练的关键长尾，没有动作标签但有海量“世界如何演化”的先验。WAM 比纯 VLA 更能消化这类无标注数据。

- [Ego4D](#)
- [EpicKitchens](#)
- [HOI4D](#)

8. 经典 World Model (奠基工作，不限机器人)

读 WAM 必须知道的经典 World Model 论文——RL/控制圈的奠基工作。

8.1 Dreamer 系列

Hafner 团队从 2018 PlaNet 一路演化到 2025 DreamerV3 + 2026 Dreamer4——经典 latent world model + actor-critic 范式，至今仍是 model-based RL 的事实标杆。DayDreamer 是首次在真机上跑 Dreamer 的工作。

- [PlaNet](#)

- [Dream to Control \(Dreamer\)](#)
- [DreamerV2](#)
- [DayDreamer](#)
- [DreamerV3](#)
- [Dreamer 4](#)

8.2 Transformer-based World Models

放弃 RSSM/RNN backbone, 换成 transformer 做世界建模——IRIS / TWM 是 Atari 上首批成功的尝试, Genie/DIAMOND/GameNGen 把它扩展到 playable game 级别。

- [IRIS \(Transformer-based WM\)](#)
- [TWM \(Transformer WM 100k\)](#)
- [Genie](#)
- [DIAMOND](#)
- [GameNGen](#)

8.3 JEPA / Latent

LeCun 力推的 Joint Embedding Predictive Architecture——核心主张是“在 latent 空间预测而非像素空间”。I-JEPA 做图像, V-JEPA 2 做视频, 后者已经接到 WAM 上 (VLA-JEPA、JEPA-VLA)。

- [A Path Towards AMI \(LeCun\)](#)
- [I-JEPA](#)
- [V-JEPA 2](#)

8.4 历史奠基 (pre-2020)

WAM 早期源头——Oh et al. 2015 ACVP 是首篇明确做 action-conditional video prediction 的工作, 可看作整个 WAM 路线的起点。

- [ACVP \(Action-Conditional Video Prediction\)](#)
 - [CLASP](#)
 - [CADDY](#)
 - [Playable Environments](#)
-

9. Navigation / Driving WM (应用线)

WM 不止用在机器人 manipulation——navigation 和 autonomous driving 是另两条独立线。

9.1 Navigation WM

世界模型用于导航——预测“如果我往那个方向走, 场景会变成啥样”, 再用预测画面选最优动作。NavigateDiff / VISTA / ForesightNav 是这条线代表, 相关综述见 navigation 专题。

- [Dynalang](#)
- [NavDreamer / WMNav](#)
- [NavigateDiff](#)
- [VISTA \(Generative Visual Imagination\)](#)
- [ForesightNav](#)
- [Do Visual Imaginations Improve VLN?](#)

9.2 Autonomous Driving WM

自动驾驶世界模型——预测周边车辆/行人未来轨迹，给 planner 做 lookahead。OccLLaMA 做 occupancy-language-action，DriveDreamer / GenAD / WoVoGen 主打 scene generation。

- [OccLLaMA](#)
- [DriveVLM](#)
- [EMMA](#)
- [DriveDreamer](#)
- [GenAD](#)
- [WoVoGen](#)

10. 选读建议（按身份）

你是	应该先读
想入门 WAM 概念	S2 综述 2605.12090 + S1 综述 2605.00080 (Section 1-3)
做 cascaded WAM 工程	UniPi → π 0.7 → NovaFlow → Vidar
做 joint diffusion WAM	UWM → Cosmos Policy → DreamZero → Fast-WAM
做 latent WM (JEPA 流)	V-JEPA 2 → VLA-JEPA → WoG → DIAL
做 WM-in-the-loop RL	UniSim → World4RL → VLA-RFT → WMPO
做 foundation video WM	Genie → Genie Envisioner → Cosmos → GigaWorld-0
关心 WAM 数据训练	Open X-Embodiment → AgiBot World → EgoVLA → DreamGen
关心评估	WorldEval → WorldGym → dWorldEval → Gemini × Veo